

TDA - Topological Data Analysis

Jamil V. Pereira & Thiago de Melo

Depto. de Matemática
IGCE – Unesp Rio Claro

UNESPetro

29 de outubro de 2024

- ① Breve apresentação - TDA
- ② Alguns exemplos
- ③ Nossos trabalhos e tratamento de dados
- ④ Referências

- Análise Topológica de Dados é uma área em rápido desenvolvimento dentro de ciência de dados, matemática e estatística.

- Análise Topológica de Dados é uma área em rápido desenvolvimento dentro de ciência de dados, matemática e estatística.
- Ela tem aplicações em ciência dos materiais, ciência biomédica, cosmologia, análise de séries temporais, inteligência artificial e em inúmeros outros domínios.


- Análise Topológica de Dados é uma área em rápido desenvolvimento dentro de ciência de dados, matemática e estatística.
- Ela tem aplicações em ciência dos materiais, ciência biomédica, cosmologia, análise de séries temporais, inteligência artificial e em inúmeros outros domínios.
- Permite o estudo de dados onde a **forma** é uma componente central.

- Análise Topológica de Dados é uma área em rápido desenvolvimento dentro de ciência de dados, matemática e estatística.
- Ela tem aplicações em ciência dos materiais, ciência biomédica, cosmologia, análise de séries temporais, inteligência artificial e em inúmeros outros domínios.
- Permite o estudo de dados onde a forma é uma componente central.
- Uma ferramenta é a homologia persistente, que mede a forma dos dados por meio de assinaturas algébricas.

- Análise Topológica de Dados é uma área em rápido desenvolvimento dentro de ciência de dados, matemática e estatística.
- Ela tem aplicações em ciência dos materiais, ciência biomédica, cosmologia, análise de séries temporais, inteligência artificial e em inúmeros outros domínios.
- Permite o estudo de dados onde a forma é uma componente central.
- Uma ferramenta é a homologia persistente, que mede a forma dos dados por meio de assinaturas algébricas.
- TDA também fornece métodos para aproximar conjuntos de dados em baixa dimensão.


Problema 1: agrupamentos

Objetivo: particionar um conjunto de dados em grupos menores que compartilham alguma semelhança.



Problema 1: agrupamentos

Objetivo: particionar um conjunto de dados em grupos menores que compartilham alguma semelhança.



Topological Mode Analysis Tool (Chazal et al. 2011)

Problema 2: assinaturas/invariantes

Objetivo: dado um objeto complicado X , criar um objeto mais simples $S(X)$ que pode dar informações sobre X .

X e Y difíceis de comparar

$$S(X) \neq S(Y) \Rightarrow X \neq Y.$$

Dada uma **família** de complexos simpliciais

$$K_0 \hookrightarrow K_1 \hookrightarrow \cdots \hookrightarrow K_n$$

aplicamos a homologia H_p sobre um corpo $\mathbb{K}$


$$H_p(K_0) \rightarrow H_p(K_1) \rightarrow \cdots \rightarrow H_p(K_n)$$

para obter uma sequência de espaços vetoriais e transformações lineares, chamada de **módulo de persistência**.

Um **módulo de persistência** $\mathbb{V}$ pode ser decomposto como uma soma de **módulos de intervalo**, o que nos dá um multiconjunto de intervalos, chamado **barcode**

$$\text{dgm}(\mathbb{V}) = \{[b, d)\}.$$

Cada intervalo $[b, d) \in \text{dgm}(\mathbb{V})$ pode ser visto como um gerador de H_p (ou seja, um buraco p -dimensional) que ‘**nasceu**’ em K_b e ‘**morreu**’ em K_d .



Source: doi.org/10.1101/540716

Pequenas mudanças em X produzem pequenas alterações nos barcodes.

Teorema

Dados X e Y espaços métricos finitos,

$$d_b(\text{dgm}(X), \text{dgm}(Y)) \leq d_{GH}(X, Y).$$

d_b : distância bottleneck;

d_{GH} : distância Gromov-Hausdorff

- Plotar o diagrama de persistência;
- Plotar gaussianas ao redor de cada ponto;
- Transformar em imagens.




Figure 1: Algorithm pipeline to transform data into a persistence image.

Detecting Carbon Nanotube Orientation with Topological Data Analysis of Scanning Electron Micrographs

Liyu Dong, Haibin Hang, Jin Gyu Park, Washington Mio, Richard Liang

“In this work, a novel methodology applying topological data analysis (TDA) to the scanning electron microscope (SEM) images was developed to **detect CNT orientation**. . . . We have quantified the CNT bundle orientation using **persistent homology**, where the data features (i.e., the CNT bundles extensions in certain directions) were summarized in an algebraic way and expressed in visible barcodes.”

Detecting Carbon Nanotube Orientation with Topological Data Analysis of Scanning Electron Micrographs

Liyu Dong, Haibin Hang, Jin Gyu Park, Washington Mio, Richard Liang




Figure 2. (a) A typical SEM image of the 30%-stretched CNT sheets (adapted from [26]); (b) the corresponding binary image as the output of the Canny edge detector; (c) an illustration of the simplified array.

Detecting Carbon Nanotube Orientation with Topological Data Analysis of Scanning Electron Micrographs

Liyu Dong, Haibin Hang, Jin Gyu Park, Washington Mio, Richard Liang





Figure 3. Various stages of the (a) sub-level and (b) super-level set filtrations of X .

Geometric and Topological Approaches to Shape Variation in Ginkgo Leaves

Haibin Hang, Martin Bauer, Washington Mio, Luke Mander

“We quantified the shape of each leaf by developing a **geometric** method based on elastic curves and a **topological** method based on persistent homology.”

“Our topological approach distinguishes long-shoot leaves from short-shoot leaves and both methods indicate that leaf shape influences or is at least related to leaf area.”




Aplicação I: folhas de soja



- Fotografias de folhas de soja cultivadas em diferentes condições.
- Detectar diferentes comportamentos (formato/área/curvatura) a partir de diferentes condições.
- Transformar cada folíolo em uma função matemática que modela tal comportamento.
- Separar cada folíolo em uma imagem, com 'mesma posição'.



Fonte: Leandra Bordignon
Universidade Federal do Acre


Primeiro passo



- Imagem é uma matriz (1700×2340) com entradas em $[0, 255]^3$ (tripla de valores RGB).
- Binarizar a imagem, ou seja, transformar em uma matriz com entradas 0, 1 (cores preto, branco).
- Dificuldades: eliminar o máximo de ruído ao binarizar (escolha do *threshold* ideal).


Threshold 30% e 75%






Utilizando recursos de *connected components* do ImageMagick, fizemos a binarização e eliminamos components conexas com área inferior a 10 mil (pixels). Após (muitos) testes, decidimos que um *threshold* satisfatório seria 62%.

Informações das componentes conexas da imagem



```
Objects (id: bounding-box centroid area mean-color):  
0: 1700x2340+0+0 881.1,1085.8 3194334 gray(100%)  
2: 1071x498+61+1264 674.6,1523.1 336325 gray(0)  
3: 834x426+355+1782 843.2,2006.4 233224 gray(0)  
1: 816x405+185+748 659.9,951.9 214117 gray(0)
```


Posicionar cada folíolo 'para cima'



- Fazer PCA–*Principal Component Analysis* em cada componente, de modo a detectar a direção de 'maior dispersão dos dados', ou seja, o 'eixo maior'.
- Calcular o ângulo θ do eixo maior com a horizontal para fazer a rotação, de modo que o folíolo fique na posição vertical.
- Ferramenta: C++ e OpenCV (Open Source Computer Vision).





- Componente 1
 $A = 229608$
 $\theta = 0.114491$
 $(c_1, c_2) = (627, 955)$
- Componente 2
 $A = 340620$
 $\theta = 354.228407$
 $(c_1, c_2) = (621, 1525)$
- Componente 3
 $A = 214117$
 $\theta = 355.508888$
 $(c_1, c_2) = (812, 2003)$




- área: já temos os valores calculados
- $d(\theta) = \text{dist}(P, C)$, onde $C = (c_1, c_2)$ é o centroide e $P = (x, y)$ é o primeiro pixel preto na altura y (existem dois deles, para intervalos de θ)
- $\text{diam}(y) = x_{\max} - x_{\min}$, onde $x_{\max}$ e $x_{\min}$ são as coordenadas x do primeiro e último pixels pretos na altura y .

Gráficos das funções $d(\theta)$








Aplicação II: *Chrysomya megacephala*




Fonte: Wikimedia

Group	D	F (g)	D/F	$\overline{W}$ (mg)	$\overline{S}$ (mm)	SR
1	75	15	5	44.42	8.89	15%
2	150	30	5	36.92	8.29	15%
3	300	60	5	49.73	9.01	41%
4	450	90	5	51.50	9.59	25%
5	150	15	10	28.02	7.57	10%
6	300	30	10	42.67	8.76	30%
7	600	60	10	28.62	7.45	58%
8	900	90	10	31.52	7.94	55%
9	300	15	20	19.55	7.19	9%
10	600	30	20	28.21	7.87	26%
11	1200	60	20	28.66	7.99	25%
12	1800	90	20	31.61	7.68	32%
13	450	15	30	23.53	7.17	15%
14	900	30	30	28.58	7.81	14%
15	1800	60	30	25.62	7.79	20%
16	2700	90	30	31.31	7.96	15%
17	600	15	40	23.28	7.24	12%
18	1200	30	40	27.18	7.27	7%
19	2400	60	40	17.82	6.62	4%
20	3600	90	40	21.06	7.16	12%

Tabela: Data for larval *C. megacephala*: larval density (D), amount of food (F), D/F ratio, mean pupal weight ($\overline{W}$), mean pupal size ($\overline{S}$), and survival rate (SR).



(a) Groups (3, 5) with $(D/F, D) = (5, 300)$ and $(10, 150)$.




(b) Groups (5, 7) with $(D/F, D) = (10, 150)$ and $(10, 600)$.

Figura: Histograms for weight distributions.

0.00	0.13	0.04	0.12	0.31	0.04	0.33	0.25	0.38	0.29	0.25	0.27	0.40	0.28	0.34	0.24	0.40	0.32	0.46	0.42
	0.00	0.31	0.42	0.29	0.18	0.32	0.22	0.37	0.25	0.14	0.21	0.40	0.23	0.31	0.18	0.39	0.27	0.46	0.41
		0.00	0.15	0.46	0.18	0.48	0.43	0.49	0.44	0.35	0.42	0.50	0.43	0.46	0.41	0.50	0.43	0.50	0.49
			0.00	0.48	0.31	0.49	0.48	0.49	0.48	0.43	0.46	0.50	0.47	0.49	0.47	0.50	0.47	0.50	0.50
				0.00	0.41	0.06	0.14	0.15	0.08	0.06	0.04	0.20	0.04	0.10	0.12	0.20	0.05	0.34	0.24
					0.00	0.44	0.38	0.46	0.39	0.28	0.35	0.48	0.37	0.43	0.35	0.48	0.36	0.49	0.47
						0.00	0.22	0.14	0.12	0.08	0.08	0.20	0.10	0.18	0.18	0.19	0.04	0.41	0.28
							0.00	0.30	0.09	0.05	0.09	0.37	0.11	0.20	0.01	0.37	0.15	0.47	0.40
								0.00	0.22	0.15	0.21	0.02	0.19	0.17	0.27	0.04	0.02	0.26	0.09
									0.00	0.03	0.10	0.28	0.04	0.12	0.07	0.28	0.12	0.42	0.33
										0.00	0.09	0.16	0.04	0.04	0.05	0.15	0.14	0.34	0.21
											0.00	0.25	0.09	0.14	0.07	0.23	0.12	0.42	0.31
												0.00	0.23	0.24	0.33	0.03	0.02	0.28	0.08
													0.00	0.04	0.10	0.22	0.12	0.40	0.28
														0.00	0.16	0.23	0.09	0.42	0.31
															0.00	0.32	0.15	0.44	0.37
																0.00	0.01	0.30	0.10
																	0.00	0.17	0.02
																		0.00	0.23
																			0.00

Tabela: d_{ws} -distance for all pairs of groups.



- ① Alice Kimie Miwa Libardi (IGCE)
- ② Jamil Viana Pereira (IGCE)
- ③ Thiago de Melo (IGCE)
- ④ Washington Mio (Florida State University)

-  S. Arvanitis and M. Detsis.
Mild explocivity, persistent homology and cryptocurrencies' bubbles: an empirical exercise.
AIMS Math., 9(1):896–917, 2024.
-  E. A. Boyd, K. B. Lazar, and S. Moysey.
Big data to support geoscience recruitment: Novel adoption of topological data analysis in geoscience education.
GSA Bulletin, 136(3-4):1458–1468, 08 2023.
-  M. Feng and M. A. Porter.
Persistent homology of geospatial data: a case study with voting.
SIAM Rev., 63(1):67–99, 2021.

-  W. Hamilton, J. E. Borgert, T. Hamelryck, and J. S. Marron.
Persistent topology of protein space.
In Research in computational topology 2, volume 30 of *Assoc. Women Math. Ser.*,
pages 223–244. Springer, Cham, [2022] ©2022.
-  L. V. Hoef, H. Adams, E. J. King, and I. Ebert-Uphoff.
A primer on topological data analysis to support image analysis tasks in
environmental science.
Artificial Intelligence for the Earth Systems, 2(1):e220039, 2023.
-  M.-J. Jimenez.
On topological analysis of cells organization in biological images.
In Discrete geometry and mathematical morphology, volume 12708 of *Lecture
Notes in Comput. Sci.*, pages 58–63. Springer, Cham, [2021] ©2021.

 S. T. Thiele, M. W. Jessell, M. Lindsay, V. Ogarko, J. F. Wellmann, and E. Pakyuz-Charrier.

The topology of geology 1: Topological analysis.

Journal of Structural Geology, 91:27–38, 2016.

 G.-W. Wei.

Characterizing musical sounds with topological data analysis.

SIAM News, 56(2):1, 3, 2023.